

## Modele Markov ascunse - TEMA

### ① Dem. formula de recurență pt. variabila forward

- Un model Markov ascuns este definit prin următoarele parametri:
- Setul de stări ascunse  $Q = \{g_1, g_2, \dots, g_N\}$  - stările prin care trăiește modelul
  - Setul de observații  $O = \{o_1, o_2, \dots, o_M\}$  - posibilele valori vizibile generate de stările ascunse
  - Vectorul de probabilitate initială  $\pi = \{\pi_i\}_{i=1}^N$  unde  $\pi_i = P(S_1 = g_i)$  - probabilitatea ca modelul să înceapă în starea  $g_i$
  - Matricea de tranziție între stări  $A = \{a_{ij}\}$  unde  $a_{ij} = P(S_{t+1} = g_j | S_t = g_i)$  descrie probabilitatea de a trece de la starea  $g_i$  la  $g_j$
  - Matricea de probabilitate de observație  $B = \{b_j(k)\}$  unde  $b_j(k) = P(O_t = o_k | S_t = g_j)$  - probabilitatea de a observa  $o_k$  atunci când modelul este în stare  $g_j$

$$\alpha_t(j) = \left[ \sum_i \alpha_{t-1}(i) a_{ij} \right] b_j(o_t)$$

Variabila forward ( $\alpha_t(j)$ ) reprezintă probabilitatea ca sevența particulară de observații  $(o_1, o_2, \dots, o_t)$  să fie generată și ca sistemul să fie în starea  $g_j$  la momentul  $t$ :

$$\alpha_t(j) = P(o_1, o_2, \dots, o_t, S_t = g_j | \lambda)$$

$S_t$  = starea sistemului la momentul  $t$

$\lambda = (A, B, \pi)$  parametrii modelului HMM

Pentru a exprima  $\alpha_t(j)$  în funcție de  $\alpha_{t-1}(i)$ , luăm în considerare că sistemul poate ajunge în starea  $g_j$  la momentul  $t$  din oricare dintre stările posibile  $g_i$  la momentul  $t-1$ .

Astfel avem:

$$\alpha_t(j) = P(o_1, o_2, \dots, o_t, S_t = g_j | \lambda)$$

Exprimăm această probabilitate în funcție de starea anterioară  $S_{t-1}$ , folosind teorema totală a probabilităților:

$$\alpha_t(j) = \sum_{i=1}^N P(o_1, o_2, \dots, o_t, S_{t-1} = g_i, S_t = g_j | \lambda)$$

Folosim proprietatea lantului Markov, conform căreia probabilitatea de a fi în starea  $S_t = g_j$  depinde de starea anterioară  $S_{t-1} = g_i$ .

Deci, descompunem astfel:

$$\alpha_t(j) = \sum_{i=1}^N P(o_t | S_t = g_j, o_1, o_2, \dots, o_{t-1}, S_{t-1} = g_i) \cdot P(S_t = g_j | S_{t-1} = g_i)$$

$$\cdot P(o_1, o_2, \dots, o_{t-1}, S_{t-1} = g_i | \lambda)$$

Într-un HMM, observațiile sunt independente de stările anterioare, starea curentă fiind dată. Deci:

$$P(o_t | S_t = g_j, o_1, o_2, \dots, o_{t-1}, S_{t-1} = g_i) = P(o_t | S_t = g_j)$$

iar, probabilitatea de tranziție  $P(S_t = g_j | S_{t-1} = g_i)$  este dată de matricea de tranziție  $A$ :

$$\alpha_t(j) = \sum_{i=1}^N P(o_t | S_t = g_j) \cdot P(S_t = g_j | S_{t-1} = g_i) \cdot P(o_1, o_2, \dots, o_{t-1}, S_{t-1} = g_i | \lambda)$$

$$\text{Vedem că } P(o_1, o_2, \dots, o_{t-1}, S_{t-1} = g_i | \lambda) = \alpha_{t-1}(i)$$

$$\alpha_t(j) = \sum_{i=1}^N \alpha_{t-1}(i) \cdot a_{ij} \cdot b_j(o_t)$$

$a_{ij} = P(S_t = g_j | S_{t-1} = g_i)$  - probabilitatea de tranziție de la starea  $g_i$  la starea  $g_j$

$b_j(o_t) = P(o_t | S_t = g_j)$  - probabilitatea de emisie a observației  $o_t$  dată de starea  $g_j$

Astfel, avem formula de recurență:

$$\alpha_t(j) = \left( \sum_{i=1}^N \alpha_{t-1}(i) \cdot a_{ij} \right) b_j(o_t)$$